

GurAI - Relatório de Evolução da Sprint 03

Chatbot com IA para mobilidade elétrica | Refatoração conversacional em LangChain

Objetivo da Sprint. A Sprint 03 evoluiu o núcleo conversacional do GurAI para LangChain LCEL, incorporando memória por sessão com limite de tokens, Structured Output com Pydantic v2, Context Engineering, versionamento do System Prompt e guardrails de segurança e escopo.

Resultado geral. O conjunto final da Sprint 03 contém 39 testes avaliados, com 39/39 aprovados na versão atual do GurAI. A execução também validou memória conversacional em uma conversa extensa e confirmou o funcionamento de bloqueios determinísticos para jailbreak, prompt injection, escopo e segurança elétrica.

1. Evolução e arquitetura

Nas Sprints 1/2, o funcionamento era conduzido por lógica manual e fluxos determinísticos/condicionais. Na Sprint 03, o núcleo conversacional foi reorganizado em uma cadeia LCEL no formato **prompt | llm | parser**, mantendo a integração documental GoodWe existente e adicionando **memória por sessão** e **Structured Output**.

Componente	Sprints 1/2	Sprint 03
Núcleo conversacional	Fluxos manuais	LCEL com ChatPromptTemplate + ChatOllama + parser
Memória	Fluxo manual/legado	RunnableWithMessageHistory + ConversationTokenBufferMemory
Saída estruturada	JSON/saída manual	Pydantic v2 + field_validator
Contexto	Prompt legado	System Prompt v2 com XML tagging
Segurança	Regras distribuídas	Guardrails de escopo, moderação e segurança elétrica

O RAG/documentação GoodWe foi preservado no fluxo principal. A decisão foi evitar uma reconstrução de recuperação mais complexa que havia apresentado maior latência, mantendo o mecanismo simples já funcional.

2. Refatoração, memória e Structured Output

LCEL. O builder centraliza o System Prompt versionado, contexto documental, histórico e pergunta em um ChatPromptTemplate. A cadeia principal utiliza ChatOllama e StrOutputParser; uma cadeia paralela utiliza with_structured_output() para os schemas de domínio.

Memória. A memória é associada a **session_id** por meio de **RunnableWithMessageHistory**. O histórico utiliza **ConversationTokenBufferMemory** com **max_token_limit=1000**. O teste de memória foi ampliado para muitos turnos e demonstrou recuperação persistente de múltiplas informações inseridas em momentos diferentes, incluindo nome, carregador, tarifa, objetivo e palavras-chave de teste.

A evidência demonstra memória conversacional em conversa extensa. O teste não é apresentado como prova isolada de que o limite de 1000 tokens foi efetivamente atingido e podado; ele comprova a persistência do contexto ao longo de múltiplos turnos.

Structured Output. Foram criados schemas **Pydantic v2** para consultas do domínio EV, incluindo **ConsultaRecarga**, **ConsultaPotenciaTotal**, **ConsultaCarregadoresDisponiveis**, **ConsultaCarregadoresAtivos** e **ConsultaEnergiaTotal**. Foram utilizados **field_validator** para padronizar identificadores e validar valores numéricos e formatos de carregadores.

No baseline, o teste **structured_output_01** foi aprovado (100% no teste disponível). Na Sprint 03, o mesmo teste foi aprovado, e a execução final do Gemma 4 manteve 39/39 testes aprovados.

3. Context Engineering e versionamento

O System Prompt foi versionado entre **v1** e **v2**. A versão **v2** reorganiza as instruções com **XML tagging** e reforça regras de escopo, segurança elétrica, prevenção de alucinação e associação documental entre identificadores de carregadores e modelos GoodWe.

Versão	Mudança	Medição
v1	Prompt legado das Sprints 1/2	1.724 tokens

Versão	Mudança	Medição
v2	XML tagging + regras de escopo, segurança e anti-alucinação	2.715 tokens (+991)

O aumento de 991 tokens representa maior quantidade de instruções e estrutura no contexto. Ele não é tratado, isoladamente, como “ganho de qualidade”; o ganho é discutido junto aos resultados de segurança, escopo e prevenção de alucinação. Mesmo com esse aumento significativo no consumo de tokens, o núcleo do GurAI foi estruturado de forma suficiente para que o aumento de tokens sejam desconsiderados.

4. Segurança e guardrails

A Sprint 03 adicionou barreiras determinísticas antes da chamada ao modelo para reduzir custo, latência e risco de execução indevida. O controle de escopo bloqueia perguntas sobre clima, política, finanças, assuntos jurídicos e temas gerais fora da finalidade operacional. O módulo de moderação foi separado para tratar jailbreak e intervenções elétricas.

Controle	Implementação	Resultado observado
Escopo	Validação determinística	Perguntas fora do escopo podem ser bloqueadas com 0 tokens
Jailbreak	Deteção normalizada sem acentos	Casos de jailbreak bloqueados antes do LLM com 0 tokens
Prompt injection	Preservação das instruções do sistema	4 testes recusados corretamente nos dois modelos
Segurança elétrica	Barreira determinística para instalação, fiação e abertura	2 testes de intervenção elétrica bloqueados com 0 tokens
Anti-alucinação	Regras explícitas de não associação e não invenção	Testes de documentação ausente retornam ausência de informação

Problemas e soluções.

- (1) O detector de jailbreak falhava quando os termos armazenados possuíam acentos, pois a entrada era normalizada sem acentos. A solução foi manter os termos de detecção normalizados.
- (2) Uma abordagem de recuperação documental por páginas aumentou complexidade e latência; o grupo retornou ao mecanismo simples já funcional.
- (3) Um caso de segurança elétrica recebia apenas uma recusa genérica; foi criada uma barreira específica para instalação, fiação, abertura e manutenção.
- (4) Havia risco de tratar charger_01 como se fosse um modelo GoodWe; o System Prompt passou a exigir associação documental explícita.

5. Resultados quantitativos e comparação antes/depois

Métrica	Sprints 1/2	Sprint 03
Qualidade no eval	30/39 positivos (76,9%)	39/39 aprovados (100%)
Latência média	1,610 s	1,795 s
Tokens por turno	Não registrado no baseline	4.054 input + 58 output em média (23 chamadas com tokens)
Structured Output	1/1 teste aprovado (100%)	1/1 teste aprovado (100%)

O baseline das Sprints 1/2 não possui métricas de tokens por teste no arquivo de resultados; por isso, essa célula é explicitamente indicada como “não registrado”, sem inferência. A latência é comparável porque está disponível nos 39 testes. A qualidade no eval considera como positivo o único caso do baseline classificado como “Resposta correta”, além dos 29 “aprovado”. Na execução atual do modelo escolhido (gemma4:31b-cloud), 39/39 testes foram aprovados. Os testes com chamada efetiva ao modelo tiveram média aproximada de 4.054 tokens de entrada, 58 tokens de saída e 4.113 tokens totais. Os caminhos determinísticos apresentam 0 tokens e não representam consumo do LLM.

6. Comparação de modelos

Para a documentação de uso de modelos, os dois modelos foram executados sobre o mesmo conjunto de 39 testes e com a mesma configuração de geração: temperature=0,3, top_p=0,9 e num_predict=1200.

Métrica	GPT-OSS 120B	Gemma 4 31B
Testes	39	39
Aprovados	37	39
Reprovados	2	0
Input tokens médios	2.905	4.054
Output tokens médios	184	58
Total tokens médios	3.089	4.113
Latência média (39 testes)	1,108 s	1,795 s

No experimento, o GPT-OSS apresentou menor latência média e menor consumo total médio de tokens, mas registrou duas reprovações: uma falha de validação do Structured Output (retorno com charger em vez de carregador) e uma resposta de suporte mais operacional do que o guardrail desejado. O Gemma 4 concluiu os 39 testes sem reprovação nesta execução.

7. Conclusão

A Sprint 03 entregou a migração do núcleo conversacional para LCEL, memória por sessão, Structured Output com Pydantic v2, Context Engineering versionado e guardrails determinísticos. O conjunto de avaliação foi reexecutado e, na configuração atual do GurAI com Gemma 4 31B, resultou em 39/39 testes aprovados.

A evolução mais relevante não está apenas na troca de componentes, mas na maior explicitação das fronteiras do sistema: o que pode responder, que dados pode usar, quando deve recusar, como preservar contexto e como estruturar saídas para integração. Os resultados também evidenciam trade-offs mensuráveis entre contexto, tokens, latência e aderência às regras.

8. Equipe

Júlia Lemos Souza - RM 569089

Erick Yu Xiang Li - RM 569305

Erick Banhos de Castro - RM 572131

Victor Henrique Nogueira Bezerra Azevedo de Souza - RM 570021

ICarlos Henrique - RM 573334

Gustavo Araújo Ramos da Silva - RM 574156