RELATÓRIO DE EVOLUÇÃO DO PROJETO

GurAI • Sprint 04 | RAG medido, confiável e utilizável

Objetivo da entrega

Documentar a evolução do GurAI, desde a plataforma e o núcleo conversacional das sprints anteriores até a avaliação do pipeline RAG da Sprint 04. Os resultados apresentados são os registrados nos artefatos do repositório original; não foram reexecutados para elaborar este relatório.

1. Resumo da evolução

O GurAI é um assistente conversacional integrado à plataforma Gurgel Enterprise, voltada à mobilidade elétrica e ao gerenciamento de carregadores. Ao longo das sprints, o projeto evoluiu da construção da plataforma e de funcionalidades operacionais para uma solução que integra interface web, backend em Python, dados de usuários, consulta documental e mecanismos de avaliação da qualidade das respostas.

A aplicação web utiliza Next.js, React e TypeScript e conversa com um backend Python baseado em FastAPI. A interface permite conversar com o GurAI e contempla funcionalidades relacionadas a veículos, sessões de recarga e cálculos de tarifação. O fluxo de pagamento é simulado e não representa processamento financeiro real.

O GurAI também recebe as sessões de recarga associadas ao usuário autenticado e pode responder perguntas sobre esse histórico, utilizando dados como carregador, veículo, duração e energia consumida, conforme a disponibilidade dos campos armazenados. Essa integração conecta o assistente a dados operacionais pessoais, além das respostas baseadas em documentação técnica.

Na Sprint 03, o núcleo conversacional foi refatorado com LangChain, memória por sessão, Structured Output, Pydantic, Context Engineering e guardrails. Na Sprint 04, o foco da avaliação passou a ser a recuperação documental, a persistência vetorial, as citações e a medição de fidelidade e relevância por meio de RAGAS e de uma rubrica manual.

2. Arquitetura e funcionalidades

Componente	Papel no projeto
Interface web	Next.js, React e TypeScript; chat integrado ao backend.
Backend e conversação	Python/FastAPI, LangChain e modelo Gemma acessado pelo Ollama Cloud.
Dados da plataforma	Firebase/Firestore para autenticação e dados associados ao usuário, incluindo sessões pessoais de recarga.
RAG documental	PyMuPDF para leitura de PDFs, chunking, recuperação híbrida e ChromaDB persistente.
Funcionalidades	Chat, cadastro de veículos, sessões de recarga e cálculo de tarifação; pagamento apenas simulado.

3. Pipeline RAG e decisões técnicas

A base documental da avaliação contém três documentos GoodWe: o datasheet GW_HCA-G2, o manual do usuário GW_HCA-G2 e o mapa MODBUS HCA-G2. Juntos, representam 81 páginas textuais disponíveis para consulta. Os artefatos atuais não comprovam a inclusão de FAQs independentes, regulamentos de carregamento em condomínios ou tabelas tarifárias oficiais; essa expansão permanece como oportunidade de evolução.

Decisão	Configuração registrada
Documentos	3 PDFs técnicos GoodWe; 81 páginas textuais.
Carregamento e divisão	PyMuPDF; RecursiveCharacterTextSplitter; 512 caracteres por chunk e overlap de 80 caracteres.
Recuperação	Estratégia híbrida com até 24 candidatos e seleção final de 4 resultados; utiliza fusão de rankings RRF.
Persistência	ChromaDB em armazenamento local persistente; índice analisado com 229 registros e vetores de 768 dimensões.
Embeddings	nomic-embed-text pelo Ollama local.
Geração	gemma4:31b-cloud pelo Ollama Cloud; temperature=0,3, top_p=0,9 e num_predict=1200 nos experimentos históricos da Sprint 03.

3.1. Decisão sobre embeddings locais

A indexação utiliza nomic-embed-text executado pelo Ollama local. A equipe encontrou dificuldades para utilizar o serviço Cloud nessa etapa e adotou a execução local, em linha com a orientação discutida com o professor sobre os problemas de depender exclusivamente de APIs remotas. O modelo gerativo continua acessado pelo Ollama Cloud, separando a vetorização local da geração de respostas remota. A configuração local é registrada de forma transparente: não corresponde à utilização de embeddings via Cloud descrita no enunciado.

3.2. Grounding, citações e limites

O pipeline preserva metadados de documento e página, e as respostas documentais avaliadas incluem referências de fonte. A checagem de citações confirma se documento e página citados aparecem no contexto recuperado; ela não prova, por si só, que todas as afirmações da resposta sejam sustentadas semanticamente. O conjunto também contém perguntas não respondíveis, usadas para avaliar manualmente se o sistema se abstém de inventar informações ausentes da base.

3.3. Estratégia de avaliação

O conjunto principal contém dez perguntas: seis respondíveis e quatro não respondíveis. O relatório RAGAS 0.4.3 calcula Faithfulness e Answer Relevancy nas seis perguntas respondíveis, utilizando Llama 3 local como avaliador e nomic-embed-text local para a etapa de relevância. As quatro recusas são revisadas separadamente por avaliação manual. Essa separação evita misturar a avaliação de respostas factuais com situações em que a conduta correta é recusar.

4. Comparativo obrigatório: antes e depois

Os artefatos consultados não contêm scores RAGAS comparáveis da versão original das Sprints 1/2. Por isso, a comparação abaixo não atribui notas retrospectivas à versão original: indica a ausência de uma medição registrada e apresenta os resultados efetivamente documentados para a Sprint 04.

Critério	Sprints 1/2 (versão original)	Sprint 04 (RAG avaliado)
Scores por iteração	Não foi identificado score RAGAS/fallback comparável nos artefatos históricos das Sprints 1/2.	RAGAS (6 perguntas respondíveis): Faithfulness v2 0,9167 → v3 0,9667; Answer Relevancy v2 0,6762 → v3 0,6757. Fallback manual (8 casos): Iteração 1 = 0,875/0,875; Iteração 2 = 1,000/1,000 para Faithfulness/Answer Relevancy.
Qualidade do contexto recuperado	Sem métrica histórica independente documentada.	Recuperação híbrida com até 24 candidatos e 4 resultados finais. Não há score standalone de Context Precision/Recall no conjunto consultado; a avaliação disponível é indireta e inclui checagem das fontes presentes no contexto.
Presença de citações	Não foi localizado resultado histórico comparável para presença de citações.	As seis respostas documentais avaliadas em cada prompt incluíram referências; 10/10 citações da v2 e 11/11 da v3 apontavam para pares documento/página presentes no contexto recuperado (precisão de presença 1,000 em ambas).
Recusa sem suporte	Sem proporção histórica comparável encontrada nos artefatos.	As quatro perguntas não respondíveis foram consideradas recusas corretas em v2 e v3 (4/4 em cada versão), conforme revisão manual.

4.1. Leitura dos resultados

Na comparação RAGAS das seis perguntas respondíveis, Faithfulness aumentou de 0,9167 para 0,9667 (+0,0500), enquanto Answer Relevancy permaneceu praticamente estável, de 0,6762 para 0,6757 (−0,0005). A versão v3 melhorou a fidelidade média nesse conjunto, mas não melhorou todas as respostas individualmente: em rag_09, Faithfulness caiu de 1,000 para 0,800. Portanto, os dados não sustentam uma conclusão de superioridade universal da v3.

Na avaliação manual, registrada separadamente em resumo_avaliacao_manual.json, as médias passaram de 0,875 para 1,000 em ambas as rubricas, em oito casos por iteração. O ganho é de 0,125 em Faithfulness e de 0,125 em Answer Relevancy. Esse resultado pertence à rubrica manual e não deve ser confundido com a comparação RAGAS.

5. Problemas encontrados e soluções adotadas

Problema 1 — Dependência de embeddings Cloud

Dificuldade: o grupo não conseguiu utilizar o Ollama Cloud para gerar embeddings de maneira confiável no ambiente do projeto. Decisão: usar nomic-embed-text pelo Ollama local e manter a geração conversacional por Gemma no Ollama Cloud. Justificativa: reduzir a dependência de serviços remotos na indexação/consulta semântica, seguindo a orientação debatida com o professor. Limite: essa decisão difere da indicação de embeddings via Cloud no enunciado e deve ser registrada como adaptação técnica.

Problema 2 — Avaliação distorcida ao misturar perguntas respondíveis e recusas

Dificuldade: uma rodada exploratória com os dez casos misturava perguntas factuais com perguntas cuja resposta correta era uma recusa. Essa mistura produziu médias menos representativas da fidelidade das respostas documentais. Decisão: separar as seis perguntas respondíveis para a comparação principal do RAGAS e avaliar manualmente as quatro perguntas não respondíveis. Justificativa: medir cada comportamento segundo o resultado esperado para o tipo de pergunta.

Problema 3 — Ganhos médios não garantem melhoria em todos os casos

Dificuldade: embora Faithfulness média tenha aumentado entre v2 e v3, houve regressão no caso rag_09. Decisão: registrar métricas agregadas e resultados por pergunta, além de manter limitações explícitas. Justificativa: evitar conclusões baseadas apenas na média e identificar casos que precisam de inspeção adicional.

6. Limitações e próximos passos

- Expandir a base documental com fontes verificadas, como FAQs, regras de carregamento compartilhado e tabelas tarifárias oficiais, caso façam parte do escopo funcional aprovado.
- Executar testes adversariais diretamente no pipeline integrado para verificar prompt injection via documentos e a qualidade semântica das citações.
- Registrar a v3 no histórico formal de versões do prompt e ampliar o conjunto de avaliação para reduzir dependência de uma amostra de dez perguntas.
- Manter explícito que o pagamento é simulado e que os resultados de avaliação não equivalem a validação de produção.