GURAI / SPRINT 04

Relatório de implementação e avaliação do RAG

Recuperação documental, grounding, citações e comparação dos prompts v2 e v3

20 de outubro de 2026

1. Resumo executivo

O Sprint 04 consolidou o fluxo de Retrieval-Augmented Generation (RAG) do GurAI sobre documentação técnica GoodWe. A solução combina uma base vetorial persistente em ChromaDB, embeddings locais nomic-embed-text, recuperação híbrida (vetorial e lexical), contexto documental enviado ao modelo generativo e respostas com referências de documento e página.

A comparação principal usa seis perguntas respondíveis avaliadas com RAGAS 0.4.3. A v3 alcançou Faithfulness de 0,967, contra 0,917 da v2 (+0,050). Answer Relevancy ficou praticamente estável. Nas quatro perguntas não respondíveis, a revisão manual considerou as recusas corretas em ambas as versões (4/4).

FAITHFULNESS V2	FAITHFULNESS V3	RECUSAS CORRETAS
0,917	0,967	4 de 4 em cada versão

A diferença de Faithfulness é promissora, mas não comprova superioridade geral da v3: a amostra tem apenas seis perguntas respondíveis, o avaliador é outro modelo de linguagem e ocorreram inconsistências de julgamento em rodadas exploratórias.

Objetivo do sprint

Demonstrar recuperação de trechos pertinentes, respostas apoiadas na documentação, citações rastreáveis e comportamento de abstenção quando a base não fornece evidência suficiente.

Fluxo resumido

1. Pergunta	2. Recuperação	3. Contexto + prompt	4. Resposta
Entrada do usuário	ChromaDB + busca lexical	Trechos recuperados e instruções	Resposta citada ou abstenção

2. Arquitetura e implementação do RAG

Corpus documental

- GW_HCA-G2_Datasheet-PT.pdf
- GW_HCA-G2_User-Manual-PT.pdf
- Mapa-MODBUS_HCA-G2.pdf

O pipeline de extração processou 81 páginas no conjunto documental. A extração de texto utiliza PyMuPDF.

Processamento e indexação

Os documentos são divididos em chunks com tamanho configurado de 512 caracteres e sobreposição de 80. Os trechos recebem metadados e IDs determinísticos e são armazenados em ChromaDB persistente no diretório data/chroma_db.

Embeddings e recuperação

O modelo de embeddings é nomic-embed-text executado pelo Ollama local. Essa escolha é intencional e está alinhada à preferência do professor; não é um serviço de embeddings Ollama Cloud. O modelo de embeddings é independente do modelo generativo.

A recuperação combina busca vetorial e lexical por Reciprocal Rank Fusion. A configuração conhecida utiliza candidate_k=24 e top_k=4. Após o diagnóstico de uma pergunta sobre potência máxima de carregamento, foi adicionada uma priorização direcionada a trechos que explicam a limitação pela potência do carregador de bordo (OBC).

Modelo generativo e parâmetros

Parâmetro	Configuração documentada
Modelo generativo	gemma4:31b-cloud
Temperature	0,3
Top-p	0,9
num_predict	1200
max_token_limit do histórico/pipeline	1000
Embeddings do RAG	nomic-embed-text (Ollama local)
Persistência vetorial	ChromaDB persistente

Grounding e evolução dos prompts

O prompt v2 define escopo, regras de segurança, resposta fundamentada e citações com arquivo e página. O prompt v3 preserva essas instruções e adiciona uma validação explícita de evidências: conferir a relação entre entidade, atributo e valor, evitar associações ambíguas e abster-se quando os contextos não sustentarem uma afirmação.

3. Desenho da avaliação

O conjunto fixo contém dez perguntas: seis respondíveis (rag_01 a rag_05 e rag_09) e quatro não respondíveis (rag_06, rag_07, rag_08 e rag_10). Nenhuma pergunta foi eliminada por pontuação baixa. Os grupos são reportados separadamente porque testam comportamentos diferentes.

Avaliação automática

RAGAS 0.4.3 foi executado em ambiente Python isolado. O Llama 3 local atua como avaliador; nomic-embed-text local fornece embeddings à métrica Answer Relevancy. A configuração testada utiliza temperature 0,0, max_workers=1 e seed 42. A comparação principal remove os blocos de citação do texto avaliado pelas métricas de resposta, mantendo os contextos recuperados; as referências são verificadas separadamente.

Métrica	Interpretação no experimento
Faithfulness	Estima se as afirmações da resposta são sustentadas pelos contextos recuperados.
Answer Relevancy	Estima a correspondência semântica entre a resposta e a intenção da pergunta.
Checagem de citações	Verifica se o documento e a página citados aparecem nos contextos recuperados.
Correção de recusa	Revisão manual das respostas nos quatro casos sem evidência suficiente.

Resultado principal: seis perguntas respondíveis

Métrica	Prompt v2	Prompt v3	Diferença v3 - v2
Faithfulness	0,917	0,967	+0,050
Answer Relevancy	0,676215	0,675706	-0,000509
Precisão média das referências verificadas	1,000	1,000	0,000

A v3 teve Faithfulness média maior neste pequeno conjunto, enquanto Answer Relevancy permaneceu praticamente inalterada. A verificação de referências encontrou os pares documento/página nos contextos, mas isso não prova semanticamente que cada afirmação esteja correta.

4. Resultados por pergunta

ID	Faith. v2	Faith. v3	Relev. v2	Relev. v3
rag_01 - Potência GW22K	1,000	1,000	0,786	0,790
rag_02 - Potência GW11K	1,000	1,000	0,786	0,790
rag_03 - Tensão GW22K	1,000	1,000	0,609	0,608
rag_04 - Corrente GW22K	0,500	1,000	0,674	0,709
rag_05 - Protocolo	1,000	1,000	0,609	0,629
rag_09 - Limite/OBC	1,000	0,800	0,592	0,528

A v3 melhorou a fidelidade do rag_04 (corrente nominal de saída), mas apresentou queda no rag_09, que exige distinguir potência nominal de saída da potência máxima de carregamento limitada pelo OBC. O rag_09 deve permanecer no conjunto de regressão. As métricas são julgamentos do Llama 3, não uma verdade de referência infalível.

Perguntas não respondíveis: revisão manual

ID	Caso	v2	v3
rag_06	Velocidade de clock não documentada	Recusa correta	Recusa correta
rag_07	Modelo GW99K-HCA-20 ausente	Recusa correta	Recusa correta
rag_08	Código 999999 desconhecido	Recusa correta	Recusa correta
rag_10	Sem vínculo de charger_01 com modelo	Recusa correta	Recusa correta

V2	V3
4/4 recusas corretas	4/4 recusas corretas

As quatro recusas foram consideradas corretas por revisão manual em cada versão. A métrica Answer Relevancy pode penalizar respostas do tipo “não encontrei a informação”; por isso, a correção da recusa é reportada separadamente, não escondida ou convertida artificialmente em score RAGAS.

5. Limitações, evolução e próximos passos

Rodada exploratória com os dez testes

Métrica	v2	v3	Observação
Faithfulness	0,680	0,537	Na v3, 9/10 notas válidas naquela rodada.
Answer Relevancy	0,408	0,410	Respostas e recusas misturadas.

Esses valores foram preservados para transparência, mas não são a comparação principal: combinam perguntas factuais e perguntas que requerem recusa; além disso, uma avaliação de Faithfulness da v3 falhou ao interpretar a saída estruturada do Llama 3. A configuração e o tratamento de erros foram ajustados nas execuções posteriores.

Limitações atuais

- A amostra contém apenas dez perguntas fixas, com seis respondíveis; não representa todos os casos de uso.
- O modelo local usado como juiz pode interpretar incorretamente afirmações ou falhar no formato de saída.
- Temperature zero e execução sequencial reduzem algumas fontes de variabilidade, mas não garantem determinismo.
- A presença de documento e página no contexto não comprova suporte semântico completo da resposta.
- As quatro recusas foram avaliadas manualmente; ainda não há uma métrica automática específica de recusa correta.
- Os resultados não demonstram generalização para perguntas fora do conjunto avaliado.

Próximas ações recomendadas

- Ampliar o conjunto com paráfrases, perguntas de segurança, prompt injection e novos casos sem evidência.
- Manter rag_09 como teste de regressão e revisar a resposta v3 sobre OBC.
- Registrar as dependências da avaliação em arquivo próprio para reproduzir o RAGAS sem alterar o ambiente principal.
- Verificar na interface de entrega que as fontes são exibidas e que a aplicação usa os mesmos contextos recuperados.

Conclusão

O GurAI possui um pipeline RAG com recuperação híbrida, persistência vetorial e geração orientada a evidências. Nos seis testes respondíveis, a v3 apresentou Faithfulness média +0,050, sem alteração relevante em Answer Relevancy; ambas as versões tiveram 4/4 recusas corretas na revisão manual. O resultado é evidência inicial de evolução, não uma prova definitiva de superioridade da v3. A pequena amostra, a variabilidade do avaliador e a regressão no rag_09 devem permanecer explícitas na apresentação final.